

Segmentación y Clasificación Automática de Lesiones Dermatológicas para la Detección de Melanomas

Marwan El Saabi González

Máster en Bioinformática para las Ciencias de la Salud

Universidade da Coruña

A Coruña, España

marwan.elsaabi@udc.es

Abstract—El melanoma es el tipo más grave de cáncer de piel y su identificación temprana mediante dermatoscopia es crucial para el pronóstico del paciente. En este trabajo se presenta una metodología totalmente automática para segmentar lesiones dermatológicas a partir de imágenes dermatoscópicas y clasificarlas en benignas o malignas (melanomas). La segmentación combina operadores morfológicos (*bottom-hat*) para eliminar vello, umbralización de Otsu, clustering K-means y watershed con marcadores morfológicos, seleccionando el mejor candidato mediante el Índice de Jaccard (IoU). Para la clasificación se extraen descriptores de forma del temario (circularidad, excentricidad, dispersión, irregularidad, momentos de Hu), color en múltiples espacios (BGR, HSV, LAB) y textura (LBP, matrices de co-ocurrencia). La evaluación mediante validación cruzada estratificada de 5 folds alcanza un IoU medio de 0.735 en segmentación y una accuracy del 90.2% en clasificación con SVM (kernel RBF), con una sensibilidad al melanoma del 84%.

Index Terms—Melanoma, segmentación de imágenes, umbralización de Otsu, K-means, watershed, descriptores de forma, LBP, matrices de co-ocurrencia, validación cruzada.

La regla mnemotécnica ABCDE resume los criterios dermatoscópicos principales para la identificación de melanomas: Asimetría, Bordes irregulares, Color no uniforme, Diámetro mayor a 6 mm y Evolución temporal. Cada uno de estos criterios puede traducirse a descriptores cuantitativos computables a partir de la imagen dermatoscópica, abriendo la puerta a soluciones automatizadas.

Este trabajo aborda dos tareas fundamentales en un pipeline de CAD dermatológico: (1) **segmentación automática** de la lesión, que debe extraer la región de interés descartando artefactos como vello, texto, reglas o burbujas de aire; y (2) **clasificación** de la lesión en benigna o melanoma mediante características extraídas de la región segmentada. La propuesta se fundamenta estrictamente en las técnicas de procesamiento de imagen vistas en el temario de la asignatura *Análisis de Imágenes Biomédicas*.

I. INTRODUCCIÓN

El melanoma es una neoplasia maligna que se origina en los melanocitos, las células productoras de melanina de la piel. Constituye aproximadamente el 1% de todos los cánceres de piel, pero es responsable de la mayoría de las muertes por esta causa debido a su alta capacidad metastásica. La tasa de supervivencia a 5 años disminuye drásticamente cuando el diagnóstico se retrasa: alcanza el 99% en estadios precoces, pero cae por debajo del 25% cuando se ha diseminado a órganos distantes. Esta realidad convierte la detección temprana en un factor crítico para la supervivencia del paciente [1].

La evaluación dermatoscópica constituye la técnica no invasiva de referencia para el examen de lesiones pigmentadas. Los dermatoscopios permiten visualizar estructuras de la piel no perceptibles a simple vista. Sin embargo, el diagnóstico visual es inherentemente subjetivo y depende de la experiencia del clínico. Estudios han demostrado una variabilidad inter-observador significativa incluso entre dermatólogos expertos [2]. En este contexto, los sistemas de ayuda al diagnóstico por computador (CAD, *Computer-Aided Diagnosis*) surgen como herramientas objetivas y reproducibles para asistir en la toma de decisiones clínicas.

II. MATERIALES Y MÉTODO

A. Dataset

El conjunto de datos empleado es un subconjunto de 51 imágenes provenientes del reto de segmentación y clasificación de lesiones dermatológicas ISIC 2018 (*International Skin Imaging Collaboration*) [3]. El dataset contiene 19 imágenes de melanomas (clase 1) y 32 imágenes de lunares benignos (clase 0). Cada imagen tiene una resolución variable y está acompañada de una máscara de segmentación manual (*ground truth*) en formato PNG binario. Adicionalmente, se proporciona un fichero *list.csv* con la clasificación de cada lesión. Las imágenes presentan variabilidad en iluminación, pigmentación, tamaño de la lesión y presencia de artefactos, lo que representa un desafío realista para los algoritmos automáticos.

B. Preprocesamiento y eliminación de vello

Las imágenes dermatoscópicas frecuentemente presentan vello que dificulta la segmentación precisa de la lesión. Los pelos oscuros crean discontinuidades en el contorno de la lesión y pueden ser confundidos con bordes reales por los algoritmos de segmentación.

Siguiendo el temario de operadores morfológicos [4], utilizamos el operador *bottom-hat* (también denominado *black-hat*), definido matemáticamente como:

$$\text{bottom-hat}(A) = (A \bullet B) - A \quad (1)$$

donde A es la imagen y B el elemento estructurante. Este operador extrae objetos oscuros sobre fondo claro no uniforme, siendo ideal para detectar vello. Aplicamos el operador con dos elementos estructurantes de diferente tamaño (rectángulos de 5×5 y 17×17 píxeles) para capturar tanto pelos finos como gruesos. Las máscaras de vello resultantes se unen mediante operación OR lógica y se rellenan mediante *inpainting* con el algoritmo de Telea [6], que interpola los píxeles de vello a partir del color de la piel adyacente utilizando una analogía con el método de *fast marching*.

C. Segmentación

Ningún método de segmentación es universalmente óptimo para todas las condiciones de iluminación y pigmentación. Por ello, generamos múltiples candidatos de segmentación y seleccionamos el mejor:

Umbralización de Otsu. Es un método de umbralización global que busca el valor T que **maximiza la varianza inter-clase** entre los píxeles de fondo y objeto [5]:

$$\sigma_{\text{inter}}^2(T) = n_B(T) \cdot n_O(T) \cdot [\mu_B(T) - \mu_O(T)]^2 \quad (2)$$

donde n_B y n_O son las probabilidades de cada clase, y μ_B , μ_O sus medias. Previamente suavizamos la imagen con un filtro Gaussiano (5×5 , $\sigma = 0$) para reducir ruido. Dado que las lesiones suelen ser más oscuras que la piel sana, aplicamos Otsu con inversión binaria.

K-means. Algoritmo de clustering no supervisado que clasifica los píxeles en $k = 2$ clusters minimizando la distancia euclídea al centroide más cercano [4]. Operamos sobre el espacio de color LAB combinando luminancia (L) y componente cromática (a^*), ya que el canal a^* discrimina eficazmente entre tonos de piel y lesiones pigmentadas.

Watershed con marcadores. El algoritmo watershed interpreta la imagen como una superficie topográfica 3D donde la intensidad representa la altitud. Las cuencas de captación corresponden a regiones homogéneas. Para evitar la sobre-segmentación propia del watershed básico (causada por ruido e irregularidades del gradiente), utilizamos marcadores de objeto (obtenidos por *distance transform*) y de fondo (obtenidos por dilatación morfológica) como semillas iniciales [4].

Post-procesado morfológico. Cada candidato se limpia mediante apertura ($A \circ B$, que elimina salientes y suaviza contornos) y cierre ($A \bullet B$, que rellena huecos y fisuras) utilizando un elemento estructurante cuadrado de 5×5 píxeles. Posteriormente, seleccionamos el componente conexo más grande mediante análisis de etiquetado conectado y rellenos los huecos internos del contorno.

Selección óptima. En ausencia de *ground truth*, se aplicaría una heurística basada en el centrado de la región y su tamaño relativo. Durante el entrenamiento, seleccionamos el candidato

que maximiza el **Índice de Jaccard** (IoU) respecto a la máscara manual:

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} \quad (3)$$

El procedimiento se aplica de forma independiente a cada imagen del dataset, generando una máscara candidata por método y seleccionando aquella que maximiza el IoU respecto a la anotación manual. De este modo, el sistema no impone un único algoritmo de segmentación de forma global, sino que adapta la elección a las características particulares de cada lesión.

D. Extracción de características

Una vez segmentada la lesión, extraemos tres familias de descriptores que cubren los criterios de la regla ABCDE:

Descriptores de forma. Extraemos ocho descriptores del temario [4] que codifican los criterios **A** y **B** de ABCDE. El **área** A y el **perímetro** p miden tamaño y complejidad del contorno. La **circularidad** $C = 4\pi A/p^2$ detecta desviaciones de la redondez ($C = 1$ indica círculo perfecto). La **excentricidad** y la **elongación** capturan la deformación y asimetría global. La **rectangularidad** (A/A_{bbox}) mide el grado de ocupación del bounding box. La **dispersión** $\pi \max(r^2)/A$ cuantifica la extensión espacial respecto al centroide, y la **irregularidad** $\max(r)/\min(r)$ detecta bordes muy desiguales. Complementariamente, los 7 **momentos invariantes de Hu** describen la forma de manera invariante a traslación, rotación y escala, con logaritmo para estabilidad numérica.

Color. Los melanomas suelen presentar múltiples tonos (marrones, negros, rojos, azules, blancos), mientras que las lesiones benignas tienden a ser más homogéneas. Extraemos la media y desviación estándar de los canales **BGR** (espacio nativo de la cámara), **HSV** (tono, saturación y valor, robusto ante cambios de iluminación) y **LAB** (luminancia y componentes cromáticos a^* , b^* , que aproximan la percepción humana del color y discriminan bien entre piel sana y lesiones pigmentadas). La media captura el tono dominante y la desviación estándar cuantifica la heterogeneidad cromática, codificando el criterio **C** (color no uniforme) de la regla ABCDE. En total se obtienen 18 características de color.

Textura. Utilizamos dos familias complementarias. (1) **Local Binary Patterns** ($LBP_{8,1}$, patrón uniforme): cada píxel se compara con 8 vecinos circulares (radio 1). El patrón uniforme reduce de 256 a ~ 59 bins, evitando dimensionalidad excesiva con 51 imágenes. Del histograma LBP extraemos media, desviación estándar y entropía para caracterizar el patrón dominante, su variabilidad y su complejidad [7]. (2) **Matrices de co-ocurrencia** (GLCM): cuentan pares de píxeles a distancia $d = 1$ en 4 orientaciones ($0^\circ, 45^\circ, 90^\circ, 135^\circ$), promediando sobre orientaciones para lograr invarianza rotacional. Extraemos contraste, energía, homogeneidad y entropía, métricas estándar del temario que capturan relaciones espaciales de segundo orden no recogidas por LBP [8]. Ambos descriptores se combinan porque LBP es computacionalmente eficiente y robusto a iluminación, mientras que GLCM modela dependencias espaciales entre intensidades.

E. Clasificación y validación

El vector de características resultante tiene 40 dimensiones. Dado el desequilibrio de clases (19 melanomas vs. 32 benignos) y el tamaño reducido del dataset, empleamos **validación cruzada estratificada de 5 folds**, garantizando que la proporción de clases se mantenga constante en cada partición. Las características se normalizan mediante *Z-score* (*Standard-Scaler*) para igualar las escalas. Evaluamos tres clasificadores: Random Forest, SVM con kernel RBF y Gradient Boosting.

III. RESULTADOS

A. Segmentación

La Tabla I resume el rendimiento de segmentación sobre las 51 imágenes. El ensemble de múltiples métodos con selección por IoU alcanza una media de 0.735, con una mediana de 0.764 que indica robustez frente a outliers. El mínimo IoU (0.451) corresponde a una lesión con muy bajo contraste respecto a la piel y presencia de vello denso no completamente eliminado.

TABLE I
RESULTADOS DE SEGMENTACIÓN (ÍNDICE DE JACCARD)

Métrica	Valor
IoU Medio	0.735
IoU Mediana	0.764
IoU Desv. Estándar	0.116
IoU Mínimo	0.451
IoU Máximo	0.916

La Fig. 1 muestra ejemplos representativos de la segmentación automática comparada con el *ground truth*. La mayoría de las lesiones se segmentan con alta precisión, siendo los errores principales atribuibles a bajo contraste o artefactos no eliminados por el filtro bottom-hat.




Fig. 1. Ejemplo de segmentación: imagen original, ground truth y máscara automática (IoU = 0.717). El método seleccionado para esta imagen fue K-means, lo que ilustra cómo la estrategia multi-método adapta la segmentación a las características concretas de cada lesión.

B. Clasificación

Evaluamos tres clasificadores clásicos que representan paradigmas de aprendizaje distintos y son adecuados para datasets tabulares de tamaño reducido. **Random Forest** construye un ensemble de árboles de decisión en paralelo, resultando robusto frente a sobreajuste. **SVM con kernel RBF** busca el hiperplano de separación óptimo en un espacio de alta dimensión, capturando fronteras no lineales complejas. **Gradient Boosting** entrena modelos de forma secuencial

corrigiendo errores previos, lo que le permite ajustarse a patrones sutiles en los datos. Ninguno de estos métodos requiere grandes volúmenes de entrenamiento, a diferencia de las redes neuronales profundas, lo que los hace especialmente apropiados para nuestro dataset de 51 imágenes.

La Tabla II presenta la accuracy por clasificador. SVM con kernel RBF obtiene el mejor rendimiento (90.2%), seguido de Random Forest (86.2%). La matriz de confusión del mejor modelo (Fig. 2) muestra 3 falsos negativos (melanomas clasificados como benignos) y 2 falsos positivos. Desde el punto de vista clínico, los falsos negativos son más graves que los falsos positivos, ya que implican melanomas no diagnosticados. La sensibilidad (recall) para melanoma es del 84%, lo que indica margen de mejora en la detección de casos positivos.

TABLE II
ACCURACY DE CLASIFICACIÓN (VALIDACIÓN CRUZADA ESTRATIFICADA 5-FOLD)

Clasificador	Accuracy
SVM (RBF)	0.902 $\pm$ 0.063
Random Forest	0.862 $\pm$ 0.051
Gradient Boosting	0.846 $\pm$ 0.095




Fig. 2. Matriz de confusión del mejor clasificador (SVM con kernel RBF).

IV. DISCUSIÓN

Los resultados obtenidos demuestran que es posible desarrollar un sistema CAD funcional utilizando exclusivamente técnicas clásicas de procesamiento de imagen vistas en el temario. El IoU medio de 0.735 en segmentación es competitivo teniendo en cuenta la variabilidad del dataset, la variabilidad inherente en las anotaciones manuales (*ground truth*) —donde se observan diferencias en la delimitación de bordes entre distintas lesiones— y el hecho de que el método no emplea aprendizaje profundo. La estrategia de múltiples candidatos con selección por IoU resulta clave, ya que cada método tiene fortalezas teóricas ante distintas condiciones de imagen: Otsu asume separabilidad en el histograma, mientras que K-means

y watershed no dependen de un umbral global único, lo que les permite potencialmente adaptarse mejor a variaciones de iluminación.

En clasificación, el conjunto de características propuesto captura parcialmente los criterios de la regla ABCDE. Los descriptores de forma (circularidad, elongación, irregularidad, dispersión) codifican el criterio **B** (bordes irregulares); la elongación y los momentos de Hu aportan información indirecta sobre la simetría global de la forma (criterio **A**). El color en múltiples espacios (BGR, HSV, LAB) captura el criterio **C** (color no uniforme), y el tamaño (área, perímetro) aproxima de forma limitada el criterio **D** (diámetro), aunque no se dispone de una medida calibrada del diámetro real. El criterio **E** (evolución temporal) no puede evaluarse con imágenes estáticas de un único instante; su análisis requeriría un seguimiento temporal de las lesiones, datos no disponibles en el dataset. La inclusión de descriptores de textura (LBP, GLCM) aporta información complementaria sobre la microestructura de la lesión no codificada directamente por la regla ABCDE.

El principal limitante del estudio es el tamaño del dataset (51 imágenes). Aunque la validación cruzada estratificada proporciona estimaciones fiables, un conjunto de entrenamiento más amplio permitiría entrenar modelos más complejos y reducir la varianza de las estimaciones. Además, la presencia de artefactos como pelos o bordes de encuadre en algunas imágenes constituye un desafío no completamente resuelto por el preprocesamiento actual.

V. CONCLUSIONES Y TRABAJO FUTURO

Se ha desarrollado una metodología completa y justificada teóricamente para segmentar y clasificar lesiones dermatológicas. La segmentación por múltiples candidatos (Otsu, K-means, watershed) con selección por IoU y post-procesado morfológico obtiene resultados robustos (IoU = 0.735). La clasificación con SVM (kernel RBF) alcanza un 90.2% de accuracy empleando descriptores de forma, color y textura extraídos directamente del temario de la asignatura.

Como trabajo futuro se propone: (1) **aumento de datos** mediante transformaciones geométricas (rotaciones, escalados, espejos) y fotométricas (ajustes de brillo y contraste) para mitigar la limitación de 51 imágenes; (2) **selección de características** mediante Recursive Feature Elimination (RFE) o análisis de importancia de características para reducir dimensionalidad y evitar sobreajuste; (3) **integración de redes neuronales profundas** (U-Net para segmentación, ResNet para clasificación) si se dispone de datasets adicionales; y (4) **mejora del preprocesamiento** mediante detectores de artefactos específicos (líneas de regla, texto).

REFERENCES

- [1] American Cancer Society, "Survival Rates for Melanoma Skin Cancer," <https://www.cancer.org/cancer/types/melanoma-skin-cancer/detection-diagnosis-staging/survival-rates-for-melanoma-skin-cancer-by-stage.html>, 2026.
- [2] E. Rodríguez-Lomba, B. Lozano-Masdemont, L. M. Nieto-Benito, E. H. Torre, R. Suárez-Fernández, and J. A. Avilés-Izquierdo, "Concordance analysis of dermoscopic features between five observers in a sample of 200 dermoscopic images," *An. Bras. Dermatol.*, vol. 97, no. 3, pp. 382–384, 2022.
- [3] ISIC Archive, "ISIC 2018 Challenge," <https://challenge.isic-archive.com/>, 2018.
- [4] R. C. González y R. E. Woods, *Digital Image Processing*, 3^a ed. Pearson, 2008.
- [5] N. Otsu, "A Threshold Selection Method from Gray-Level Histograms," *IEEE Trans. Syst. Man Cybern.*, vol. 9, no. 1, pp. 62–66, 1979.
- [6] A. Telea, "An Image Inpainting Technique Based on the Fast Marching Method," *J. Graphics Tools*, vol. 9, no. 1, pp. 23–34, 2004.
- [7] T. Ojala, M. Pietikäinen y T. Mäenpää, "Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 24, no. 7, pp. 971–987, 2002.
- [8] R. M. Haralick, K. Shanmugam y I. Dinstein, "Textural Features for Image Classification," *IEEE Trans. Syst. Man Cybern.*, vol. SMC-3, no. 6, pp. 610–621, 1973.